EXPOSÉ ZUR MASTERARBEIT

Kalibrierte probabilistische Geolokalisierung von Nadir-Luftbildern anhand von OpenStreetMap-Objektmerkmalen

Eine Generalisierungsstudie über Regionen

Calibrated Probabilistic Geolocalization of Nadir Imagery with OpenStreetMap Features: A Cross-Region Generalization Study

Masterstudiengang Data Science & Intelligent Analytics (berufsbegleitend) · Hochschule Kufstein Tirol

1. Ausgangssituation und Problemstellung

Drohnen bestimmen ihre Position in der Regel über globale Satellitennavigationssysteme (GNSS). Fällt das Signal aus, wird es gestört oder im Gebirge abgeschattet, bietet die visuelle Lokalisierung gegen georeferenzierte Referenzdaten eine Alternative, bezeichnet als *Visual Terrain-Relative Navigation* oder *Absolute Visual Localization* (Couturier & Akhloufi, 2021; Jarraya et al., 2025). Verbreitet ist der Abgleich der Aufnahme mit Orthofotos oder Satellitenbildern; erreicht werden mittlere Fehler unter 8 m in 200 m Flughöhe (Goforth & Lucey, 2019) bzw. unter 50 m nach rund 2 km Flugstrecke (Kinnari et al., 2021). Solche Verfahren sind jedoch empfindlich gegenüber Jahreszeit und Beleuchtung, weshalb gezielt saisoninvariante Verfahren entwickelt wurden (Kinnari et al., 2022; Kinnari et al., 2023), und ihre Genauigkeit hängt von der Struktur des Geländes ab (Conte & Doherty, 2009).

Kartendaten wie OpenStreetMap (OSM) sind eine frei verfügbare, weniger erscheinungsabhängige Referenz. Costea und Leordeanu verorten Luftbilder über Straßenkreuzungen, deren Nachbarschaft sie mit OSM abgleichen, und lokalisieren rund 90 % der Kreuzungen auf 2,5 m genau (Costea & Leordeanu, 2016). Andere Arbeiten gleichen bodennahe Kamerabilder mit OSM ab (Sarlin et al., 2023), vergleichen erkannte Objekte über einen Szenengraphen mit OSM-Landmarken (Kunz et al., 2021) oder nutzen Gebäudeumrisse aus Vektorkarten in einem Partikelfilter (Ouyang et al., 2024). Weitere Ansätze übersetzen Luftbilder in kartenähnliche Darstellungen (Schleiss, 2019), setzen GIS-Daten zur Geolokalisierung ein (Wei et al., 2022) oder schlagen semantisch gewichtete Partikelfilter vor (Yuan et al., 2025); die Abhängigkeit der visuellen Navigation von der Flughöhe untersuchen Castleberry und Martin (Castleberry & Martin, 2021).

Diese Arbeit betrachtet den schwierigsten Fall: ein senkrecht aufgenommenes Luftbild (Nadir-Aufnahme) *ohne Metadaten*, also ohne Position, Flughöhe, Blickrichtung oder Kameradaten. Position, Maßstab und Ausrichtung müssen allein aus dem Bildinhalt bestimmt werden. Dazu werden zunächst Objekte erkannt, die auch in OSM verzeichnet sind: Schwimmbecken, Tennis- und Fußballplätze, Laufbahnen, Lagertanks sowie Gebäude, unterschieden nach Wohn- und Nebengebäuden; Strommasten und Straßenkreuzungen sind als Erweiterung vorgesehen. Anschließend wird bestimmt, wo die erkannte Anordnung auf der Karte am wahrscheinlichsten liegt.

In ländlichen und alpinen Regionen ist das schwierig: Gebiete ohne klare semantische Merkmale gelten als offenes Problem (Jarraya et al., 2025; Zheng et al., 2026). Eine explorative Vorprüfung am bayerischen Alpenrand[1] zeigt, dass nur 0,1–1,6 % zufälliger Bildausschnitte von 500 × 375 m genügend punktförmige OSM-Objekte enthalten, mit Gebäuden und Kreuzungen 34 %, während 22 % kein kartiertes Merkmal aufweisen. Ein unangepasster, vortrainierter Detektor erreichte Precision 0,49 und Recall 0,62, und ein Abgleich, der nur passende Objekte zählt, lieferte bei regelmäßigen Anordnungen (Tanklager) eine falsche Position mit hoher Sicherheit. Es fehlt ein Verfahren, das Erkennungsfehler

[1] KI-gestützte Machbarkeitsprüfung mit offenen Daten (DOP20, OSM); in der Masterarbeit eigenständig zu wiederholen.

explizit berücksichtigt, seine Unsicherheit verlässlich angibt und sich enthält, wenn ein Bild nicht verortbar ist.

2. Relevanz

Praktisch ist GNSS-unabhängige Lokalisierung bei Signalausfall oder -störung, bei Abschattung im Gebirge, für Rettungseinsätze, die nachträgliche Verortung von Luftbildern und die Pflege offener Kartendaten bedeutsam (Couturier & Akhloufi, 2021; Jarraya et al., 2025). Entscheidend ist nicht nur, *wo* ein Bild liegt, sondern *wie sicher* diese Aussage ist: Eine falsche, aber als sicher ausgegebene Position ist gefährlicher als eine begründete Enthaltung.

Theoretisch existieren die Bausteine einzeln: der Abgleich erkannter Objekte mit OSM-Landmarken (Kunz et al., 2021), Vektorkarten mit Partikelfiltern (Ouyang et al., 2024), die Analyse, wann ununterscheidbare Landmarken eine Verortung erlauben (Hu et al., 2024)†, und die Ablehnung mehrdeutiger Lösungen auf semantischen Karten, die bislang nur synthetisch und ausdrücklich nicht mit realen Flügen geprüft wurde (Trukhina & Vashkelis, 2026). Nicht gefunden wurde ihre Kombination: in Nadir-Luftbildern erkannte Objektklassen, ein explizites Fehlermodell des Detektors in einer Wahrscheinlichkeitsfunktion, eine kalibrierte Positionsverteilung mit Nullhypothese und eine räumlich getrennte Prüfung der Übertragbarkeit zwischen Regionen auf realen Daten.

3. Zielsetzung und Ergebnisse

Wissenschaftlich soll (1) die Erkennungsgüte der genannten OSM-Objektklassen in Nadir-Luftbildern gemessen und als Fehlermodell beschrieben werden (Trefferrate, Fehlalarme, Verwechslungen, Lagefehler), (2) ein probabilistisches Verortungsverfahren mit diesem Fehlermodell, kalibrierter Positionsverteilung und Nullhypothese „nicht verortbar“ entwickelt und (3) seine Übertragbarkeit auf eine andere Region geprüft werden. Praktisch entsteht ein Prototyp, in den ein Luftbild hochgeladen wird und der Positionsverteilung, Unsicherheit oder Enthaltung ausgibt. Erwartete Ergebnisse sind Kennzahlen je Objektklasse, Erfolgsquoten und Fehler je Region, eine Bewertung der Kalibrierung, die Enthaltungsrate als Maß für die Grenzen der Methode sowie Empfehlungen zu nötigen Kartenmerkmalen.

> **Forschungsfrage:** Wie zuverlässig und wie gut kalibriert lassen sich Nadir-Luftbilder ohne Metadaten allein anhand erkannter OpenStreetMap-Objekte verorten, und wie gut überträgt sich das Verfahren auf eine andere Region?
> - **FF1:** Mit welcher Güte lassen sich ausgewählte OSM-Objektklassen in Luftbildern mit 0,2 m Bodenauflösung erkennen, und wie lassen sich die Detektorfehler als Fehlermodell beschreiben?
> - **FF2:** Verbessert eine Wahrscheinlichkeitsfunktion mit Fehlermodell und Nullhypothese Trefferquote und Kalibrierung gegenüber einem Abgleich, der nur übereinstimmende Objekte zählt?
> - **FF3:** Wie verändern sich Erkennung, Verortungserfolg, Kalibrierung und Enthaltungsrate beim Übertrag vom Alpenvorland (Lkr. Miesbach) ins Hochgebirge (Lkr. Garmisch-Partenkirchen)?

4. Vorgehensweise und Methoden

Die Arbeit folgt einem gestaltungsorientierten Vorgehen: Ein Verfahren wird als Artefakt entwickelt und quantitativ evaluiert [Rahmenwerk belegen].

Daten. Referenz sind OSM-Objekte aus der Overpass-API mit festem Abrufdatum (OpenStreetMap-Mitwirkende, 2026)† Bilddaten sind die amtlichen Orthophotos DOP20 (0,2 m, CC BY 4.0) (Bayerische Vermessungsverwaltung, 2026)†. Daraus entstehen metadatenfreie Testbilder mit zufälliger Lage und Drehung, deren wahre Position nur der Auswertung bekannt ist. Die Bodenauflösung ist keine Studienachse; das Verfahren kennt den Maßstab aber nicht und durchsucht 0,1–0,3 m pro Pixel.

Erkennung (FF1). Ein auf dem Luftbild-Datensatz DOTA (Xia et al., 2018)† vortrainierter Detektor mit gedrehten Rahmen wird mit aus OSM abgeleiteten Labels feinabgestimmt. Die Evaluation je Klasse liefert das Fehlermodell.

Verortung (FF2). Für Hypothesen aus Ort, Drehung und Maßstab werden die OSM-Objekte ins Bild projiziert. Die Wahrscheinlichkeit berücksichtigt übereinstimmende Erkennungen (Trefferrate, Verwechslung, Lagefehler), übersehene Kartenobjekte und Fehlalarme als Poisson-Punktprozess. Über ein Hypothesenraster entsteht eine Positionsverteilung, die gegen die Nullhypothese „alle Erkennungen sind Fehlalarme“ geprüft wird; der Term für übersehene Objekte soll Fehlzuordnungen bei regelmäßigen Anordnungen verhindern. Vergleichsverfahren ist ein robuster Abgleich über die Zahl übereinstimmender Objekte (Fischler & Bolles, 1981)†.

Kalibrierung und Evaluation (FF3). Die ausgegebene Sicherheit wird mit der beobachteten Trefferquote verglichen, etwa über Zuverlässigkeitsdiagramme [Quelle], und daraus eine Enthaltungsschwelle abgeleitet. Trainings-, Abstimmungs- und Testgebiete werden räumlich getrennt; abgestimmt wird in Miesbach, getestet in Garmisch-Partenkirchen. Gemessen werden Erfolgsquote (Fehler unter [X] m), Positions-, Maßstabs- und Richtungsfehler, Kalibrierungsfehler und Enthaltungsrate; rund 100 Testbilder je Bedingung ergeben Konfidenzintervalle von etwa ± 10 Prozentpunkten. Abschließend wird das Verfahren in den Upload-Prototyp integriert.

Abgrenzung. Ausgeschlossen sind Schrägaufnahmen, Echtzeit-Navigation, ein Wechsel des Bildanbieters und die Bodenauflösung als Studienachse; die Arbeit ist auf zivile Anwendungen ausgerichtet.

Literatur

Bayerische Vermessungsverwaltung. (2026). *Digitales Orthophoto 20 cm (DOP20) RGB [Datensatz]*. https://geodaten.bayern.de/opengeodata/OpenDataDetail.html?pn=dop20rgb

Castleberry, M., & Martin, S. (2021). Improving Visual Terrain Relative Navigation for Aerial Systems at Diverse Altitudes. *Autonomous Systems: Sensors, Processing, and Security for Vehicles and Infrastructure 2021*, *11748*, 1174802. https://doi.org/10.1117/12.2587350

Conte, G., & Doherty, P. (2009). Vision-Based Unmanned Aerial Vehicle Navigation Using Geo-Referenced Information. *EURASIP Journal on Advances in Signal Processing*, *2009*(1), 387308. https://doi.org/10.1155/2009/387308

Costea, D., & Leordeanu, M. (2016). Aerial Image Geolocalization from Recognition and Matching of Roads and Intersections. *arXiv*. https://doi.org/10.48550/arXiv.1605.08323

Couturier, A., & Akhloufi, M. A. (2021). A Review on Absolute Visual Localization for UAV. *Robotics and Autonomous Systems*, *135*, 103666. https://doi.org/10.1016/j.robot.2020.103666

Fischler, M. A., & Bolles, R. C. (1981). Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography. *Communications of the ACM*, *24*(6), 381–395.

Goforth, H., & Lucey, S. (2019). GPS-Denied UAV Localization Using Pre-Existing Satellite Imagery. *2019 International Conference on Robotics and Automation (ICRA)*, 2974–2980. https://doi.org/10.1109/ICRA.2019.8793558

Hu, H., Dhillon, H. S., & Buehrer, R. M. (2024). Foundations of Vision-Based Localization: A New Approach to Localizability Analysis Using Stochastic Geometry. *arXiv*. https://arxiv.org/abs/2409.09525

Jarraya, I., Al-Batati, A., Kadri, M. B., Abdelkader, M., Ammar, A., Boulila, W., & Koubaa, A. (2025). GNSS-Denied Unmanned Aerial Vehicle Navigation: Analyzing Computational Complexity, Sensor Fusion, and Localization Methodologies. *Satellite Navigation*, *6*(1), 9. https://doi.org/10.1186/s43020-025-00162-z

Kinnari, J., Renzulli, R., Verdoja, F., & Kyrki, V. (2023). LSVL: Large-Scale Season-Invariant Visual Localization for UAVs. *Robotics and Autonomous Systems*, *168*, 104497. https://doi.org/10.1016/j.robot.2023.104497

Kinnari, J., Verdoja, F., & Kyrki, V. (2021). GNSS-Denied Geolocalization of UAVs by Visual Matching of Onboard Camera Images with Orthophotos. *2021 20th International Conference on Advanced Robotics (ICAR)*, 555–562. https://doi.org/10.1109/ICAR53236.2021.9659333

Kinnari, J., Verdoja, F., & Kyrki, V. (2022). Season-Invariant GNSS-Denied Visual Localization for UAVs. *IEEE Robotics and Automation Letters*, *7*(4), 10232–10239. https://doi.org/10.1109/LRA.2022.3191038

Kunz, M., Vierling, A., Wolf, P., & Berns, K. (2021). Localization Using OSM Landmarks. *2021 Latin American Robotics Symposium (LARS), 2021 Brazilian Symposium on Robotics (SBR), and 2021 Workshop on Robotics in Education (WRE)*, 228–233. https://doi.org/10.1109/LARS/SBR/WRE54079.2021.9605475

OpenStreetMap-Mitwirkende. (2026). *OpenStreetMap [Datensatz]*. https://www.openstreetmap.org/

Ouyang, C., Hu, S., Long, F., Shi, S., Yu, Z., Zhao, K., You, Z., Pi, J., & Xing, B. (2024). A Semantic Vector Map-Based Approach for Aircraft Positioning in GNSS/GPS Denied Large-Scale Environment. *Defence Technology*, *34*, 1–10. https://doi.org/10.1016/j.dt.2023.07.006

Sarlin, P.-E., DeTone, D., Yang, T.-Y., Avetisyan, A., Straub, J., Malisiewicz, T., Bulo, S. R., Newcombe, R., Kontschieder, P., & Balntas, V. (2023). OrienterNet: Visual Localization in 2D Public Maps with Neural Matching. *arXiv*. https://doi.org/10.48550/arXiv.2304.02009

Schleiss, M. (2019). Translating Aerial Images into Street-Map-Like Representations for Visual Self-Localization of UAVs. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, *XLII-2-W13*, 575–580. https://doi.org/10.5194/isprs-archives-XLII-2-W13-575-2019

Trukhina, N., & Vashkelis, V. (2026). SASGeo: Stability-Aware Semantic Map Localization for GNSS-Denied UAVs – A Framework and Synthetic Proof of Concept. *arXiv*. https://doi.org/10.48550/arXiv.2607.07737

Wei, J., Karakay, D., & Yilmaz, A. (2022). A GIS Aided Approach for Geolocalizing an Unmanned Aerial System Using Deep Learning. *arXiv*. https://doi.org/10.48550/arXiv.2208.12251

Xia, G.-S., Bai, X., Ding, J., Zhu, Z., Belongie, S., Luo, J., Datcu, M., Pelillo, M., & Zhang, L. (2018, Juni). DOTA: A Large-Scale Dataset for Object Detection in Aerial Images. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

Yuan, J., Dai, M., Zheng, E., Su, C., Chen, N., Hu, Q., Zhu, S., & Cao, Y. (2025). SWA-PF: Semantic-Weighted Adaptive Particle Filter for Memory-Efficient 4-DoF UAV Localization in GNSS-Denied Environments. *arXiv*. https://doi.org/10.48550/arXiv.2509.13795

Zheng, J., Huang, Y., Dai, R., Liu, R., Chen, Y., Peng, K., Yang, K., Zhang, J., Wang, G., Wysocki, O., & Stiefelhagen, R. (2026). SeqLoc: Beyond the Single Frame for Cross-View Geo-Localization in Feature-Sparse Scenes. *arXiv*. https://arxiv.org/abs/2608.07835v2

† noch nicht selbst geprüfte Quelle.