EXPOSÉ ZUR MASTERARBEIT

Kalibrierte probabilistische Geolokalisierung von Nadir-Luftbildern anhand von OpenStreetMap-Objektmerkmalen

Eine Generalisierungsstudie über Regionen

Calibrated Probabilistic Geolocalization of Nadir Imagery with OpenStreetMap Features: A Cross-Region Generalization Study

Masterstudiengang Data Science & Intelligent Analytics (berufsbegleitend) · Hochschule Kufstein Tirol

1. Ausgangssituation und Problemstellung

Unbemannte Luftfahrzeuge bestimmen ihre Position in der Regel über globale Satellitennavigationssysteme (GNSS). Fällt das Signal aus, wird es gestört oder im Gebirge abgeschattet, fehlt diese Grundlage. Als Alternative hat sich die visuelle Lokalisierung gegen georeferenzierte Referenzdaten etabliert, in der Literatur als *Visual Terrain-Relative Navigation* oder *Absolute Visual Localization* bezeichnet (Couturier & Akhloufi, 2021; Jarraya et al., 2025). Bereits frühe Arbeiten zeigen, dass ein Abgleich von Kamerabildern mit georeferenzierten Luftbildern lange GNSS-Ausfälle überbrücken kann, die erreichbare Genauigkeit aber von der Struktur des überflogenen Geländes abhängt (Conte & Doherty, 2009).

Ein verbreiteter Ansatz vergleicht die Aufnahme direkt mit Orthofotos oder Satellitenbildern. Damit werden mittlere Fehler von unter 8 m in 200 m Flughöhe (Goforth & Lucey, 2019) bzw. unter 50 m nach rund 2 km Flugstrecke in einem Partikelfilter (Kinnari et al., 2021) erreicht. Solche Bild-zu-Bild-Verfahren sind jedoch empfindlich gegenüber Jahreszeit, Vegetation und Beleuchtung, weshalb gezielt saisoninvariante Verfahren entwickelt wurden (Kinnari et al., 2022; Kinnari et al., 2023).

Eine Alternative sind Kartendaten als Referenz. OpenStreetMap (OSM) ist frei verfügbar, weltweit vorhanden und beschreibt Objekte statt Erscheinungsbilder. Costea und Leordeanu verorten Luftbilder über Straßenkreuzungen, deren Nachbarschaft sie als Fingerabdruck mit OSM abgleichen, und lokalisieren so rund 90 % der Kreuzungen auf 2,5 m genau (Costea & Leordeanu, 2016). Weitere Arbeiten gleichen bodennahe Kamerabilder mit Sub-Meter-Genauigkeit gegen OSM ab (Sarlin et al., 2023), vergleichen erkannte Objekte über einen Szenengraphen mit OSM-Landmarken für Bodenroboter (Kunz et al., 2021) oder nutzen Gebäudeumrisse aus Vektorkarten in einem Partikelfilter (Ouyang et al., 2024). Daneben werden Luftbilder in kartenähnliche Darstellungen übersetzt (Schleiss, 2019), GIS-Daten zur Geolokalisierung eingesetzt (Wei et al., 2022) und semantisch gewichtete Partikelfilter vorgeschlagen (Yuan et al., 2025).

Diese Arbeit betrachtet den schwierigsten Fall: Gegeben ist ausschließlich ein senkrecht aufgenommenes Luftbild (Nadir-Aufnahme) *ohne Metadaten*, also ohne Position, Flughöhe, Blickrichtung oder Kameradaten. Position, Maßstab und Ausrichtung müssen allein aus dem Bildinhalt bestimmt werden. Dazu müssen zunächst Objekte erkannt und klassifiziert werden, die auch in OSM verzeichnet sind, etwa Schwimmbecken, Sportplätze, Tanks, Masten und Gebäude [Objektklassen endgültig festlegen]. Anschließend ist zu entscheiden, an welcher Stelle der Karte die erkannte Anordnung am wahrscheinlichsten liegt und ob eine Verortung überhaupt verlässlich möglich ist.

Gerade in ländlichen und alpinen Regionen ist das schwierig. Übersichtsarbeiten nennen Gebiete ohne klare semantische Merkmale, insbesondere bei geringer Flughöhe, als offenes Problem (Jarraya et al., 2025), und neuere Arbeiten widmen sich gezielt merkmalsarmen Szenen (Zheng et al., 2026).

Eine explorative Vorprüfung im Untersuchungsraum am bayerischen Alpenrand bestätigt das[1]: Nur 0,1–1,6 % zufällig gewählter Bildausschnitte von 500 × 375 m enthalten genügend punktförmige OSM-Objekte, mit Gebäuden und Straßenkreuzungen steigt der Anteil auf 34 %, und 22 % enthalten gar kein kartiertes Merkmal. Ein ohne Anpassung eingesetzter, vortrainierter Detektor erreichte dort eine Precision von 0,49 bei einem Recall von 0,62. Zudem zeigte sich, dass ein einfacher Abgleich über die Anzahl passender Objekte bei regelmäßig angeordneten Objekten (z. B. einem Tanklager) eine falsche Position mit hoher Sicherheit ausgeben kann. Es fehlt somit ein Verfahren, das Erkennungsfehler explizit berücksichtigt, seine Unsicherheit verlässlich angibt und sich enthält, wenn ein Bild nicht verortbar ist.

2. Relevanz

Praktische Relevanz. GNSS-unabhängige Lokalisierung ist für Drohnen und Luftbildauswertung bedeutsam: bei Signalausfall oder -störung, bei Abschattung im Gebirge, für Such- und Rettungseinsätze, für die nachträgliche Verortung von Luftbildern und für die Pflege offener Kartendaten (Couturier & Akhloufi, 2021; Hehelskyi & Avrutov, 2025; Jarraya et al., 2025). Eine Kartenreferenz wie OSM ist frei verfügbar und weniger von Jahreszeit und Beleuchtung abhängig als bildbasierte Referenzen (Kinnari et al., 2022). Für einen Einsatz entscheidend ist dabei nicht nur *wo* ein Bild liegt, sondern *wie sicher* diese Aussage ist: Eine falsche, aber als sicher ausgegebene Position ist in der Navigation gefährlicher als eine begründete Enthaltung.

Theoretische Relevanz. Die Bausteine einer objektbasierten, kartengestützten Verortung existieren einzeln: der Abgleich erkannter Objekte mit OSM-Landmarken (Kunz et al., 2021), Vektorkarten mit Partikelfiltern (Ouyang et al., 2024), die Analyse, wann ununterscheidbare Landmarken eine Verortung erlauben (Hu et al., 2024)[†], sowie die Ablehnung mehrdeutiger Lösungen auf semantischen Karten, die bislang allerdings nur synthetisch erprobt und ausdrücklich nicht mit realen Flügen validiert ist (Trukhina & Vashkelis, 2026). Kartenbasierte Verfahren wurden zudem überwiegend bodennah und in Städten untersucht (Sarlin et al., 2023; Terlizzi & Fathian, 2026). Nicht gefunden wurde die Kombination, die diese Arbeit untersucht: in Nadir-Luftbildern erkannte Objektklassen, ein explizites Fehlermodell des Detektors innerhalb einer Wahrscheinlichkeitsfunktion, eine kalibrierte Positionsverteilung mit Nullhypothese und eine räumlich getrennte Prüfung der Übertragbarkeit zwischen Regionen auf realen Daten.

3. Zielsetzung und Ergebnisse

Wissenschaftliche Ziele. Erstens soll die Erkennungs- und Klassifikationsgüte ausgewählter OSM-Objektklassen in Nadir-Luftbildern gemessen und als Fehlermodell beschrieben werden, bestehend aus Trefferrate je Klasse, Fehlalarmrate, Verwechslungen zwischen Klassen und Lageungenauigkeit. Zweitens soll ein probabilistisches Verortungsverfahren entwickelt werden, das dieses Fehlermodell nutzt, eine kalibrierte Positionsverteilung liefert und gegen die Nullhypothese „nicht verortbar“ prüft. Drittens soll untersucht werden, wie gut Erkennung, Verortung und Kalibrierung von einer Region auf eine andere übertragbar sind.

Praktisches Ziel. Als Prototyp entsteht eine Anwendung, in die ein Luftbild hochgeladen wird und die erkannte Objekte, eine Positionsverteilung samt Unsicherheit oder eine begründete Enthaltung ausgibt.

[1] KI-gestützte Machbarkeitsprüfung mit offenen Daten (DOP20, OSM); in der Masterarbeit eigenständig zu wiederholen.

Erwartete Ergebnisse. Erwartet werden Kennzahlen der Erkennung je Objektklasse, Erfolgsquoten und Positionsfehler je Region, Aussagen zur Kalibrierung der ausgegebenen Sicherheit, die Enthaltungsrate als Maß für die Grenzen der Methode sowie Empfehlungen, welche Kartenmerkmale für eine verlässliche Verortung in ländlichen und alpinen Räumen nötig sind.

Forschungsfragen [Entwurf — mit der Betreuung fixieren]:

> **Hauptfrage:** Wie zuverlässig und wie gut kalibriert lassen sich Nadir-Luftbilder ohne Metadaten allein anhand erkannter OpenStreetMap-Objekte verorten, und wie gut lässt sich das Verfahren auf eine andere Region übertragen?
>
> **FF1:** Mit welcher Güte lassen sich ausgewählte OSM-Objektklassen in Nadir-Luftbildern mit 0,2 m Bodenauflösung erkennen und klassifizieren, und wie lassen sich die Fehler des Detektors als Fehlermodell beschreiben?
>
> **FF2:** Verbessert eine Wahrscheinlichkeitsfunktion mit explizitem Fehlermodell und Nullhypothese die Trefferquote und die Kalibrierung gegenüber einem Abgleich, der nur die Anzahl übereinstimmender Objekte zählt?
>
> **FF3:** Wie verändern sich Erkennungsgüte, Verortungserfolg, Kalibrierung und Enthaltungsrate beim Übertrag vom Alpenvorland (Landkreis Miesbach) ins Hochgebirge (Landkreis Garmisch-Partenkirchen)?

4. Vorgehensweise und Methoden

Rahmen. Die Arbeit verortet sich in der Terrain-Relative Navigation (Castleberry & Martin, 2021; Couturier & Akhloufi, 2021) und folgt einem gestaltungsorientierten Vorgehen: Ein Verfahren wird als Artefakt entwickelt und quantitativ evaluiert [methodisches Rahmenwerk mit Quelle belegen].

Daten. Als Referenzkarte dienen OSM-Objekte, die über die Overpass-API abgefragt und mit Abrufdatum gesichert werden (OpenStreetMap-Mitwirkende, 2026)†. Als Bilddaten dienen die amtlichen digitalen Orthophotos DOP20 der Bayerischen Vermessungsverwaltung mit 0,2 m Bodenauflösung (Lizenz CC BY 4.0) (Bayerische Vermessungsverwaltung, 2026)†. Aus ihnen werden metadatenfreie Testbilder erzeugt: Ausschnitte an zufälliger Position mit zufälliger Drehung, deren wahre Lage nur der Auswertung bekannt ist. Die Bodenauflösung wird nicht als Studienachse variiert; dem Verfahren ist der Maßstab dennoch unbekannt, es durchsucht einen Bereich von 0,1–0,3 m pro Pixel. Untersuchungsräume sind der Landkreis Miesbach (Alpenvorland) und der Landkreis Garmisch-Partenkirchen (Hochgebirge).

Schritt 1: Erkennung (FF1). Ausgangspunkt ist ein auf dem Luftbild-Datensatz DOTA (Xia et al., 2018)† vortrainierter Detektor mit gedrehten Begrenzungsrahmen (Ultralytics, 2024)†. Er wird mit aus OSM abgeleiteten Labels feinabgestimmt; ungenaue Kartenlabels werden dabei bewusst als verrauschte Trainingsdaten behandelt (Maggiori et al., 2017)†. Die Evaluation je Klasse liefert das Fehlermodell: Trefferrate, Fehlalarmrate, Verwechslungsmatrix und Lagefehler.

Schritt 2: Verortung (FF2). Für eine Positionshypothese aus Ort, Drehung und Maßstab werden die OSM-Objekte des betreffenden Kartenausschnitts in das Bild projiziert. Die Wahrscheinlichkeit der Hypothese setzt sich aus drei Teilen zusammen: übereinstimmenden Erkennungen (bewertet mit Trefferrate, Verwechslungswahrscheinlichkeit und Lagefehler), Kartenobjekten ohne Erkennung (bewertet mit der Wahrscheinlichkeit, übersehen zu werden) und Erkennungen ohne Kartenobjekt (modelliert als Fehlalarme eines Poisson-Punktprozesses). Über ein Raster von Hypothesen entsteht eine Positionsverteilung, die gegen die Nullhypothese „alle Erkennungen sind Fehlalarme“ geprüft wird. Gerade der Term für übersehene Kartenobjekte soll Fehlzuordnungen bei regelmäßigen Objektanordnungen

verhindern. Als Vergleich dient ein robuster Abgleich, der nur übereinstimmende Objekte zählt (Fischler & Bolles, 1981)†.

Schritt 3: Kalibrierung. Die ausgegebene Sicherheit wird mit der beobachteten Trefferquote verglichen, etwa über Zuverlässigkeitsdiagramme [Quelle zur Kalibrierung ergänzen]. Daraus wird eine Schwelle abgeleitet, unterhalb derer sich das Verfahren enthält.

Schritt 4: Evaluation und Generalisierung (FF3). Trainings-, Abstimmungs- und Testgebiete werden räumlich getrennt (z. B. in Blöcken von 2 km), um Überschätzung durch räumliche Nähe zu vermeiden. Abgestimmt wird in Miesbach, getestet in Garmisch-Partenkirchen. Gemessen werden die Erfolgsquote (Positionsfehler unter [X] m), Positions-, Maßstabs- und Richtungsfehler, Kalibrierungsfehler und Enthaltungsrate. Etwa 100 Testbilder je Bedingung ergeben Konfidenzintervalle von rund ± 10 Prozentpunkten.

Schritt 5: Prototyp. Das Verfahren wird in eine Upload-Anwendung integriert, die Erkennungen, Positionsverteilung und Enthaltungen darstellt.

Abgrenzung. Nicht Gegenstand der Arbeit sind Schrägaufnahmen, Echtzeit-Navigation, ein Wechsel des Bildanbieters und die Bodenauflösung als Studienachse. Die Arbeit ist auf zivile Anwendungen ausgerichtet.

Literatur

Bayerische Vermessungsverwaltung. (2026). *Digitales Orthophoto 20 cm (DOP20) RGB [Datensatz].* https://geodaten.bayern.de/opengeodata/OpenDataDetail.html?pn=dop20rgb

Castleberry, M., & Martin, S. (2021). Improving Visual Terrain Relative Navigation for Aerial Systems at Diverse Altitudes. *Autonomous Systems: Sensors, Processing, and Security for Vehicles and Infrastructure 2021*, *11748*, 1174802. https://doi.org/10.1117/12.2587350

Conte, G., & Doherty, P. (2009). Vision-Based Unmanned Aerial Vehicle Navigation Using Geo-Referenced Information. *EURASIP Journal on Advances in Signal Processing*, *2009*(1), 387308. https://doi.org/10.1155/2009/387308

Costea, D., & Leordeanu, M. (2016). Aerial Image Geolocalization from Recognition and Matching of Roads and Intersections. *arXiv*. https://doi.org/10.48550/arXiv.1605.08323

Couturier, A., & Akhloufi, M. A. (2021). A Review on Absolute Visual Localization for UAV. *Robotics and Autonomous Systems*, *135*, 103666. https://doi.org/10.1016/j.robot.2020.103666

Fischler, M. A., & Bolles, R. C. (1981). Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography. *Communications of the ACM*, *24*(6), 381–395.

Goforth, H., & Lucey, S. (2019). GPS-Denied UAV Localization Using Pre-Existing Satellite Imagery. *2019 International Conference on Robotics and Automation (ICRA)*, 2974–2980. https://doi.org/10.1109/ICRA.2019.8793558

Hehelskyi, O., & Avrutov, V. (2025). Methods of UAV Navigation in Difficult Environmental Conditions. *Mechanics of Gyroscopic Systems*, (49), 31–44. https://doi.org/10.20535/0203-3771492025334103

Hu, H., Dhillon, H. S., & Buehrer, R. M. (2024). Foundations of Vision-Based Localization: A New Approach to Localizability Analysis Using Stochastic Geometry. *arXiv*. https://arxiv.org/abs/2409.09525

Jarraya, I., Al-Batati, A., Kadri, M. B., Abdelkader, M., Ammar, A., Boulila, W., & Koubaa, A. (2025). GNSS-Denied Unmanned Aerial Vehicle Navigation: Analyzing Computational Complexity, Sensor

Fusion, and Localization Methodologies. *Satellite Navigation*, *6*(1), 9. https://doi.org/10.1186/s43020-025-00162-z

Kinnari, J., Renzulli, R., Verdoja, F., & Kyrki, V. (2023). LSVL: Large-Scale Season-Invariant Visual Localization for UAVs. *Robotics and Autonomous Systems*, *168*, 104497. https://doi.org/10.1016/j.robot.2023.104497

Kinnari, J., Verdoja, F., & Kyrki, V. (2021). GNSS-Denied Geolocalization of UAVs by Visual Matching of Onboard Camera Images with Orthophotos. *2021 20th International Conference on Advanced Robotics (ICAR)*, 555–562. https://doi.org/10.1109/ICAR53236.2021.9659333

Kinnari, J., Verdoja, F., & Kyrki, V. (2022). Season-Invariant GNSS-Denied Visual Localization for UAVs. *IEEE Robotics and Automation Letters*, *7*(4), 10232–10239. https://doi.org/10.1109/LRA.2022.3191038

Kunz, M., Vierling, A., Wolf, P., & Berns, K. (2021). Localization Using OSM Landmarks. *2021 Latin American Robotics Symposium (LARS), 2021 Brazilian Symposium on Robotics (SBR), and 2021 Workshop on Robotics in Education (WRE)*, 228–233. https://doi.org/10.1109/LARS/SBR/WRE54079.2021.9605475

Maggiori, E., Tarabalka, Y., Charpiat, G., & Alliez, P. (2017). Convolutional Neural Networks for Large-Scale Remote-Sensing Image Classification. *IEEE Transactions on Geoscience and Remote Sensing*.

OpenStreetMap-Mitwirkende. (2026). *OpenStreetMap [Datensatz]*. https://www.openstreetmap.org/

Ouyang, C., Hu, S., Long, F., Shi, S., Yu, Z., Zhao, K., You, Z., Pi, J., & Xing, B. (2024). A Semantic Vector Map-Based Approach for Aircraft Positioning in GNSS/GPS Denied Large-Scale Environment. *Defence Technology*, *34*, 1–10. https://doi.org/10.1016/j.dt.2023.07.006

Sarlin, P.-E., DeTone, D., Yang, T.-Y., Avetisyan, A., Straub, J., Malisiewicz, T., Bulo, S. R., Newcombe, R., Kontschieder, P., & Balntas, V. (2023). OrienterNet: Visual Localization in 2D Public Maps with Neural Matching. *arXiv*. https://doi.org/10.48550/arXiv.2304.02009

Schleiss, M. (2019). Translating Aerial Images into Street-Map-Like Representations for Visual Self-Localization of UAVs. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, *XLII-2-W13*, 575–580. https://doi.org/10.5194/isprs-archives-XLII-2-W13-575-2019

Terlizzi, G., & Fathian, K. (2026). Large-Scale Geometric Map-Based Localization of UAVs in GNSS-Denied Urban Environments. *arXiv*. https://doi.org/10.48550/arXiv.2609.28225

Trukhina, N., & Vashkelis, V. (2026). SASGeo: Stability-Aware Semantic Map Localization for GNSS-Denied UAVs – A Framework and Synthetic Proof of Concept. *arXiv*. https://doi.org/10.48550/arXiv.2607.07737

Ultralytics. (2024). *Ultralytics YOLO11 [Software]*. https://github.com/ultralytics/ultralytics

Wei, J., Karakay, D., & Yilmaz, A. (2022). A GIS Aided Approach for Geolocalizing an Unmanned Aerial System Using Deep Learning. *arXiv*. https://doi.org/10.48550/arXiv.2208.12251

Xia, G.-S., Bai, X., Ding, J., Zhu, Z., Belongie, S., Luo, J., Datcu, M., Pelillo, M., & Zhang, L. (2018, Juni). DOTA: A Large-Scale Dataset for Object Detection in Aerial Images. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*.

Yuan, J., Dai, M., Zheng, E., Su, C., Chen, N., Hu, Q., Zhu, S., & Cao, Y. (2025). SWA-PF: Semantic-Weighted Adaptive Particle Filter for Memory-Efficient 4-DoF UAV Localization in GNSS-Denied Environments. *arXiv*. https://doi.org/10.48550/arXiv.2509.13795

Zheng, J., Huang, Y., Dai, R., Liu, R., Chen, Y., Peng, K., Yang, K., Zhang, J., Wang, G., Wysocki, O., & Stiefelhagen, R. (2026). SeqLoc: Beyond the Single Frame for Cross-View Geo-Localization in Feature-Sparse Scenes. *arXiv*. https://arxiv.org/abs/2608.07835v2

† Quelle aus `kandidaten.bib`: noch nicht selbst geprüft.